

Prédiction de la fibrillation atriale incidente à partir d'ECG 12-dérivations et de données cliniques (MIMIC-IV) : valeur incrémentale de représentations gelées et adaptées sous évaluation de survie pré-enregistrée

Certificat de spécialisation IA en Santé

Rémi Castaing

août 2026

Résumé

Contexte. La fibrillation atriale (FA) incidente, souvent silencieuse, expose à un risque accru d'AVC et d'insuffisance cardiaque. La prédire à partir d'un ECG où le patient est indemne diffère de la détection d'une FA présente, et l'apport propre de l'ECG au-delà des facteurs cliniques reste contesté. **Objectif.** Déterminer si une représentation d'un ECG 12-dérivations apporte une valeur prédictive incrémentale au-delà d'un modèle clinique — et laquelle, des marqueurs conventionnels aux embeddings d'un encodeur gelé puis adapté — sous une évaluation de survie rigoureuse sur MIMIC-IV. **Méthodes.** Cohorte de 138 083 patients indemnes à l'ECG index ; décès en risque concurrent, censure pondérée (IPCW), séparation par patient. Six bras figés par un pré-enregistrement signé ont été estimés en une **passé unique** sur un jeu de test verrouillé (27 618 patients, 838 événements à un an), jamais utilisé pour sélectionner. **Résultats.** La fusion clinique + embeddings gagne **+0,058 d'AUC à un an** sur le modèle clinique (IC 95 % [+0,047 ; +0,069]), avec des risques cause-spécifiques calibrés. En pratique prédictive, la représentation apprise couvre l'information des marqueurs ; l'inverse n'est pas vrai. L'apport de l'adaptation, donné pour acquis en développement, **n'est pas établi** sur la réserve (+0,004, IC contenant zéro). **Limites.** Biais de surveillance et de sélection (base mono-centre), labels incomplets, puissance limitée pour les petits écarts, pas de validation externe. **Conclusion.** L'ECG apporte une information prédictive que le dossier clinique ne contient pas ; le dispositif de mesure permet de l'affirmer sans réserve de sélection — comme de retirer ce qui ne tenait pas. Aucune utilité clinique n'est revendiquée avant validation externe.



1 Introduction

La fibrillation atriale (FA) est l'arythmie soutenue la plus fréquente, et son fardeau croît avec le vieillissement des populations [1]. Souvent silencieuse ou paroxystique, elle peut rester longtemps non diagnostiquée alors même qu'elle expose à un risque accru d'accident vasculaire cérébral — y compris d'infarctus cérébraux silencieux [2] —, de déclin cognitif indépendant de l'AVC [3] et d'insuffisance cardiaque. Identifier tôt les patients à risque a donc un intérêt clinique direct, notamment pour orienter la surveillance des sujets encore asymptomatiques.

Il faut d'emblée distinguer trois problèmes que l'on confond aisément. Le premier est de **détecter** une FA sur un tracé où elle s'exprime. Le deuxième, plus subtil, est de reconnaître la **signature d'une FA déjà existante** (souvent paroxystique) sur un ECG enregistré en rythme sinusal : le patient a une FA, mais le tracé courant est normal — c'est la tâche des algorithmes d'IA-ECG popularisés par Attia et coll. [4]. Le troisième, le nôtre, est de **prédire une FA incidente** : estimer, à partir d'un ECG où le patient est *réellement indemne*, la probabilité qu'il développe une FA *dans le futur* [5]. Ces trois régimes ne partagent ni la même population ni la même utilité clinique. Ce travail porte sur le troisième — la prédiction d'une FA incidente chez des patients sans FA documentée à l'ECG index —, la FA prévalente (déjà présente ou antérieure) étant exclue par construction.

Cette tâche de prédiction est aussi la plus difficile des trois, et sa difficulté croît avec l'horizon : une synthèse récente des études d'IA-FA par horizon temporel observe une discrimination qui passe d'environ 0,90 à un mois à environ 0,60 au-delà de quatre ans, soit une perte de l'ordre de 0,03 point d'AUC par doublement de l'horizon [6]. Les horizons cliniquement utiles — un à deux ans, ceux de ce travail — se situent donc dans la zone où le signal est le plus ténu.

La valeur prédictive propre de l'ECG y reste d'ailleurs **incertaine**, et la littérature récente est contradictoire. Certains travaux rapportent qu'un modèle profond appliqué à l'ECG dépasse un score clinique de référence [7], tandis que d'autres le trouvent inférieur en validation externe [8], ou concluent que l'ECG et le clinique sont d'un niveau comparable, seule leur **combinaison** apportant un gain [9,10]. Autrement dit, la question n'est pas « l'ECG contient-il un signal ? » mais « ce signal ajoute-t-il quelque chose à ce que l'on prédit déjà cliniquement ? » — et cette question est réellement ouverte.

Ce travail propose une démarche pour y répondre de façon défendable, et l'applique. Plutôt que d'opposer un modèle à un autre, il compare des niveaux d'information croissants — clinique de référence, marqueurs ECG conventionnels, représentations apprises d'un encodeur pré-entraîné **gelé**, puis **adapté** à la tâche, et leur fusion — sous une évaluation de survie rigoureuse (décès en risque concurrent, censure pondérée, séparation au niveau patient), sur la base MIMIC-IV. Parce que les écarts en jeu sont petits devant les sources de variabilité de la mesure (graine aléatoire, sélection de configurations), la démarche culmine dans un **dispositif de mesure** explicite : comparateurs appariés, lecture des écarts contre leur dispersion, et passe d'estimation finale **pré-enregistrée** sur un jeu de test verrouillé. Cette passe a été exécutée, et les résultats rapportés ici en sont issus ; tout chiffre antérieur est dit, et reste, un chiffre de développement.

2 Objectifs et questions de recherche

2.1 Objectif général

Ce travail vise à **déterminer si, et dans quelle mesure, une représentation d'un ECG 12-dérivations apporte une valeur prédictive incrémentale pour la fibrillation atriale**

(FA) incidente au-delà d'un modèle clinique de référence.

La formulation est délibérément étroite. Elle ne demande pas si l'ECG « permet de prédire la FA » dans l'absolu, mais s'il ajoute une information à ce que l'on sait déjà prédire cliniquement. Ce déplacement est essentiel : la performance d'un modèle riche ne se juge qu'à son **apport incrémental** sur une référence simple.

2.2 Le modèle clinique : un comparateur, pas une question

Savoir qu'un score clinique prédit la FA incidente n'est pas une question de recherche : c'est un acquis. CHARGE-AF est un score validé sur de multiples cohortes [11,12], et les modèles cliniques de FA incidente ont été largement revus [12]. Le modèle clinique joue donc ici le rôle de **comparateur** — le mètre-étalon que toute approche fondée sur l'ECG doit dépasser pour être jugée utile.

Une nuance méthodologique en découle, et elle appartient aux méthodes (section 4), non aux objectifs : la performance publiée d'un score ne se transporte pas automatiquement d'une population à l'autre. Sa discrimination varie fortement en validation externe [12], et un modèle performant dans sa cohorte d'origine peut se révéler inférieur ailleurs [8]. Le comparateur principal est donc un modèle clinique **entraîné sur notre propre cohorte**, sur les variables disponibles à l'index, pour que la comparaison soit équitable. Le score CHARGE-AF publié, dont toutes les variables ne sont disponibles que pour une petite fraction des patients de MIMIC-IV, est rapporté comme **repère secondaire** sur ce sous-groupe, avec ses coefficients publiés — jamais « ré-estimé », ce qui en ferait un autre modèle.

2.3 Questions de recherche

L'objectif général se décline en trois questions testables.

- **Q1 — Apport incrémental.** Une fois le modèle clinique de référence établi sur la cohorte, l'ECG apporte-t-il une information *complémentaire*, à *valeur incrémentale*, par rapport au dossier clinique ? La littérature est ici contradictoire : certaines études rapportent un gain de l'ECG profond sur le score clinique [7], d'autres le trouvent inférieur en validation externe [8]. Cette question est donc réellement ouverte.
- **Q2 — Quelle représentation de l'ECG ?** Parmi les représentations candidates, laquelle apporte le plus : des *marqueurs ECG conventionnels* interprétables [13], les *embeddings* d'un encodeur pré-entraîné **gelé** — et lequel —, ou les embeddings d'un encodeur **adapté** à la tâche par fine-tuning efficient en paramètres [14] ? Cette question sépare l'apport de la représentation apprise de celui de marqueurs explicables, puis demande si l'adaptation ajoute quelque chose au gelé.
- **Q3 — La rigueur méthodologique change-t-elle la conclusion ?** Un traitement de survie propre (décès en risque concurrent, censure pondérée par IPCW) modifie-t-il l'apport *apparent* de l'ECG par rapport aux études qui traitent l'issue comme une classification binaire à censure naïve [7,8] ? Cette question porte l'exigence d'esprit critique du projet : une part des écarts rapportés dans la littérature pourrait tenir au cadre d'évaluation autant qu'au signal.

Ces trois questions structurent l'ensemble du document : la section Méthodes décrit comment chacune est rendue mesurable — y compris le dispositif qui protège la mesure elle-même —, et la Discussion revient sur ce que les résultats permettent, ou non, d'en conclure.

3 Données et population

3.1 Sources

Les données proviennent de MIMIC-IV, base hospitalière rétrospective mono-centre (population de soins aigus, dont les limites de généralisabilité sont discutées en section 7) [15], et de son sous-ensemble d'électrocardiogrammes 12-dérivations MIMIC-IV-ECG [16]. Les diagnostics (codes ICD-9 et ICD-10) et les comptes rendus servent à définir l'événement et les covariables cliniques ; les tracés ECG fournissent le signal d'entrée des modèles ECG.

3.2 De l'ECG index à la cohorte à risque

L'unité d'analyse est un patient, observé à partir de son **ECG index** — le premier ECG 12-dérivations pour lequel il est indemne de FA. Sont exclus, avant de définir la cohorte, tous les patients porteurs d'une FA au moment de l'index, codée antérieurement, ou survenant dans une **période de blanking de 14 jours** après l'index (flutter inclus dans la définition de l'événement). Cette exclusion garantit que l'on étudie bien une FA *incidente* et non une FA *prévalente* déjà présente. La figure Figure 1 détaille l'attrition : des 161 352 patients disposant d'un ECG, l'exclusion d'un ECG index en FA (−10 007), d'une FA codée avant l'index (−3 282), d'une FA dans la fenêtre de blanking (−6 702) puis des suivis nuls et covariables manquantes (−3 278) conduit à la cohorte à risque.

Toutes les covariables cliniques sont datées **avant** l'ECG index (prévention de la fuite temporelle, section 4). Les choix de définition contestables — inclusion du flutter, durée du blanking, traitement de la censure précoce — sont couverts par des analyses de sensibilité dédiées (SA-001 à SA-003), dont les conclusions sont citées en section 7.

Dès l'assemblage de la cohorte, **20 % des patients (27 618) sont réservés dans un jeu de test verrouillé** (échantillonnage stratifié sur le sexe, la tranche d'âge et le statut d'événement, affectation déterministe par patient) : aucune étape d'entraînement, de sélection ou de comparaison n'y accède avant la passe d'estimation finale décrite en section 4. Tous les effectifs et résultats présentés hors de cette passe portent sur les 110 465 patients de développement.

3.3 Événement, risque concurrent et censure

L'événement d'intérêt est la survenue d'une **FA incidente** (codes ICD I48.x / 427.31–32, complétés par les mentions du compte rendu). Le **décès sans FA** est traité comme un **risque concurrent** et non comme une simple perte de vue : un patient décédé ne peut plus développer de FA, et le compter comme censuré ordinaire surestimerait le risque. L'incidence cumulée est donc estimée en présence de risque concurrent (Aalen-Johansen) : elle vaut **4,3 % à un an, 6,5 % à deux ans et 12,6 % à cinq ans**, ce dernier horizon étant marqué exploratoire (censure lourde). L'écart avec un Kaplan-Meier naïf, visible figure Figure 2, est faible mais se creuse avec le temps (+0,2 point à un an, +1,3 point à cinq ans), cohérent avec une mortalité concurrente non négligeable.

La prédiction est évaluée à horizon fixe : **1 an en primaire, 2 ans en secondaire**. Un horizon à 5 ans est calculé mais reste **exploratoire**, la censure y devenant trop lourde pour une estimation fiable (voir ci-dessous).

3.4 Description de la cohorte

La cohorte de référence compte **138 083 patients** indemnes à l'index. Sur cette population, la FA incidente et le décès concurrent s'observent aux fréquences brutes suivantes — proportions sur




FIGURE 1 : Diagramme de flux de la cohorte : inclusions et exclusions successives, jusqu'à la cohorte à risque indemne à l'ECG index (run de référence 10e4c416a6fa).




FIGURE 2 : Incidence cumulée de la FA : estimateur en présence de risque concurrent (CIF, Aalen-Johansen) vs Kaplan-Meier naïf. L'écart traduit la part de décès concurrents.

l'ensemble du suivi, à distinguer de l'incidence cumulée à un horizon donné (tableau Table 1) — pour un suivi médian de **402,5 jours**.

TABLE 1 : Effectifs de la cohorte de référence (10e4c416a6fa).

	n	%
Éligibles	138 083	100 %
FA incidentes	9 416	6,8 %
Décès concurrents	11 792	8,5 %
Censurés	116 875	84,6 %

Le trait dominant de cette cohorte est une **censure précoce et massive** : 40,2 % des patients sont censurés avant un an, 46,2 % avant deux ans et 58,7 % avant cinq ans. Ce profil (figure Figure 3) reflète la structure de MIMIC — de nombreux patients consultent une fois puis échappent au suivi — plutôt qu'un artefact de calcul. Il justifie de placer les horizons à 1 et 2 ans au premier plan et de ne lire l'horizon à 5 ans que comme exploratoire ; il motive aussi le traitement rigoureux de la censure décrit en section 4 (pondération IPCW).




FIGURE 3 : Distribution de la durée de suivi (après blanking J14). La censure précoce est importante ; l'accumulation à l'horizon administratif traduit la fin de fenêtre d'observation.

3.5 Contrôles de cohérence

La construction de la cohorte est assortie de contrôles automatiques, tous satisfaits sur le run de référence : absence de durée de suivi non positive, cohérence des statuts d'événement, réconciliation

est mesuré, contre quoi il est lu, et ce qui protège l'estimation finale de nos propres choix. La figure Figure 4 en donne la vue d'ensemble.




FIGURE 4 : Schéma du pipeline : de l'ECG index et du dossier clinique aux représentations, aux têtes de survie et à l'évaluation appariée, jusqu'à la passe unique pré-enregistrée sur le jeu verrouillé.

4.1 Prévention des fuites d'information

Trois fuites classiques sont neutralisées par construction.

La **fuite temporelle** d'abord : aucune variable postérieure à l'ECG index ne peut entrer dans un modèle. Les covariables cliniques (comorbidités notamment) ne sont retenues que si leur code de diagnostic est daté *avant* l'index ; ce filtre s'applique aux codes ICD-9 comme ICD-10, les deux versions coexistant dans MIMIC-IV. La sélection de la cohorte et la définition de l'événement (section 3) obéissent au même principe.

La **fuite au niveau de la validation** ensuite : toute séparation apprentissage/évaluation se fait au niveau **patient** (`subject_id`), jamais au niveau de l'ECG. Un même patient possédant plusieurs tracés, un découpage au niveau ECG placerait des enregistrements du même individu de part et d'autre de la frontière et gonflerait artificiellement les performances. Les rééchantillonnages d'incertitude (voir plus bas) tirent également des `subject_id`, jamais des ECG.

Une **troisième fuite, propre aux embeddings**, tient à l'encodeur pré-entraîné. Plusieurs modèles de fondation ECG candidats sont pré-entraînés sur MIMIC-IV [17,18] : si des patients de la cohorte ont servi à ce pré-entraînement, leur présence simultanée dans l'entraînement de l'encodeur et dans l'évaluation constituerait une fuite. Le non-chevauchement patients pré-entraînement / évaluation est donc vérifié ; lorsqu'il ne peut l'être pour un encodeur externe, la limite est explicitement déclarée (section 7). L'encodeur retenu pour l'adaptation, ST-MEM [19], est pré-entraîné hors de MIMIC, ce qui écarte ce risque pour le volet adapté.

4.2 Représentations comparées : une échelle à un facteur par barreau

Le projet ne compare pas un modèle à un autre, mais des **niveaux d'information croissants**, afin d'isoler l'apport propre de chacun (objectif général, Q1–Q2) :

1. **Clinique seul** — un modèle entraîné sur les variables cliniques **disponibles à l’ECG index** (démographie, comorbidités) ; c’est le comparateur principal. Le score CHARGE-AF publié [11] est calculé, avec ses coefficients d’origine, sur le sous-groupe des patients dont toutes ses variables sont disponibles — une petite fraction de la cohorte — et rapporté comme **repère secondaire** : le ré-estimer sur nos données en ferait un autre modèle, et sa performance publiée ne se transporte de toute façon pas telle quelle d’une population à l’autre [8,12].
2. **Marqueurs ECG conventionnels** — mesures interprétables de l’ECG (à la manière d’un score ECG simple [13]). Cette marche teste si un signal ECG *explicable* suffit. L’absence d’une mesure chez un patient est traitée comme une variable à part entière, non comme un trou à imputer silencieusement.
3. **Embeddings d’encodeurs gelés** — représentations issues d’un encodeur pré-entraîné dont les poids ne sont pas modifiés. Plutôt que de figer un encodeur d’avance, quatre sont comparés — ST-MEM [19], ECG-JEPA [20], ECGFounder [21], ECG-FM [17] —, un benchmark récent montrant qu’aucun ne domine universellement [22].
4. **Embeddings d’un encodeur adapté** — le même encodeur, adapté à la tâche (voir ci-dessous). Cette marche isole l’apport de l’*adaptation*, à représentation, tête et covariables par ailleurs identiques.
5. **Fusion multimodale** — clinique + représentation ECG, pour mesurer l’apport incrémental de l’ECG au-delà du clinique (Q1).

4.3 Adaptation de l’encodeur

L’adaptation suit une stratégie de **fine-tuning efficient en paramètres** : une correction de rang faible (LoRA [14]) est apprise par-dessus l’encodeur ST-MEM gelé, plutôt qu’un réglage de tous les poids — une voie qui divise le nombre de paramètres entraînés par plusieurs ordres de grandeur et limite la déformation de la représentation pré-entraînée, dont on sait qu’un fine-tuning complet peut dégrader la robustesse [23].

Trois garde-fous encadrent cette adaptation.

La fonction de perte. La vraisemblance partielle de Cox, critère usuel des modèles de survie, ne se décompose pas en mini-lots : son ensemble à risque couple chaque patient à tous ceux qui le suivent dans le temps. L’entraînement par lots d’un réseau impose donc une perte de **survie en temps discret**, cause-spécifique, qui s’évalue lot par lot — la log-vraisemblance d’un modèle à risques concurrents discrétisé [24, sans son terme de ranking], telle qu’implémentée dans la bibliothèque pycox [25]. Le fine-tuné et sa référence gelée sont comparés à **perte et grille de discrétisation identiques**, condition pour attribuer un écart à l’encodeur plutôt qu’à un artefact de modélisation.

La tête pendant l’adaptation. La tête de survie est **fonctionnellement gelée** pendant l’adaptation de l’encodeur — exclue de l’optimiseur *et* figée en évaluation —, de sorte que le déplacement mesuré soit celui de la représentation, pas un mélange indiscernable des deux. Ce choix s’inspire de l’enseignement du **sondage linéaire préalable** (*linear probing then fine-tuning*) : régler la tête avant de déplacer l’encodeur évite que le début d’entraînement ne détruise la représentation pré-entraînée [23].

La jauge de déplacement. Une corrélation de rang (Spearman) entre les risques prédits par l’encodeur adapté et par l’encodeur gelé sert de **jauge** : elle borne l’ampleur du déplacement de la représentation. C’est un instrument de *sélection* des runs candidats — écarter ceux qui se sont effondrés ou n’ont pas bougé — et non une métrique de performance : elle n’entre dans aucun tableau de résultats.

Augmentations du signal. Trois familles d’augmentation sont évaluées pendant l’adaptation : le décalage temporel, la rotation du vectocardiogramme [26,27] et le masquage temporel — un choix informé par la revue systématique du domaine [28] et sa généalogie [29]. Leur composition obéit à une discipline stricte : un point d’application unique dans la chaîne de chargement, un ordre fixe, et un générateur aléatoire propre à chaque élément (la reproductibilité d’un tirage ne dépend pas des augmentations activées en amont). L’effet attendu est borné : la littérature situe le gain des augmentations près de zéro dès que l’effectif d’entraînement est confortable, leur rôle étant plutôt de freiner la mémorisation [30].

Ordre des dérivations. Les douze dérivations de MIMIC-IV-ECG ne sont pas rangées dans l’ordre attendu par les encodeurs pré-entraînés : deux d’entre elles y sont permutées. Un ECG douze dérivations n’étant pas un jeu de courbes interchangeable — chaque canal est un point de vue géométrique distinct sur la même dépolarisation —, l’effet a été mesuré par double extraction sur un échantillon du développement, jamais sur le jeu verrouillé : il s’est révélé **sous la résolution de la mesure** et de signe non déterminé (+0,0066 de C-index à 4 000 patients, −0,0028 à 12 000, les deux intervalles contenant zéro), soit l’ordre de grandeur du bruit de graine. La correction a néanmoins été appliquée **avant** toute ouverture du jeu de test, dans l’adaptateur de chaque encodeur et en aval des augmentations : elle ne coûtait alors rien en gouvernance, et toutes les représentations de l’échelle en sont issues. Les représentations d’origine ne sont ni supprimées ni réécrites — elles portent un nom de registre distinct et restent l’historique de développement consultable.

4.4 Familles de modèles et traitement de la censure

Le suivi de MIMIC-IV est court et lourdement censuré (40,2 % des patients avant un an, section 3), et cette censure est probablement informative. Deux familles de modèles coexistent donc, et **aucune ne traite la censure naïvement** :

- une famille de **survie** (modèles cause-spécifiques de type Cox régularisé, y compris une implémentation différentiable pour les représentations de grande dimension) qui gère la censure par construction ;
- une famille de **classification à horizon fixe** (régression logistique, gradient boosting) qui, elle, exige un label binaire à un horizon H . Pour les patients censurés avant H , ce label est inconnu ; le compter comme « pas de FA » fabriquerait des faux négatifs en masse. On applique donc une **pondération par l’inverse de la probabilité de censure (IPCW)** [31] : le modèle de censure est estimé sur l’apprentissage de chaque pli uniquement (sous peine de fuite), et labels comme métriques sont repondérés. Le décès avant H sans FA est traité comme **non-événement** (cible cause-spécifique), cohérent avec le décès en risque concurrent (section 3).

Cette précision est importante pour la question Q3 : la classification à horizon n’est pas rejetée *en soi* — nous l’employons — mais uniquement dans sa version **pondérée IPCW**, par opposition aux travaux qui traitent l’issue comme une classification binaire à censure naïve.

4.5 Évaluation : une suite figée, une monnaie commune

Pour que « Δ AUC de l’ECG sur le clinique » ait un sens, tous les modèles sont jugés sur la **même règle** : le **risque absolu prédit de FA à l’horizon H** (1 an en primaire, 2 ans en secondaire ; 5 ans non visé, l’estimation de la censure y devenant instable). Toutes les métriques sont estimées au niveau patient sur les plis de validation, pondérées IPCW pour la censure, l’« observé » d’une

calibration étant l'incidence cumulée en présence de risque concurrent (Aalen-Johansen) et non un Kaplan-Meier naïf. La suite couvre trois axes complémentaires :

- **discrimination** — AUC dépendant du temps à H et C-index d'Uno [32], complétés par l'AUPRC, pertinente car la FA incidente est un événement rare (incidence cumulée de 4,3 % à un an, section 3) ;
- **calibration** — courbe de calibration (prédit vs incidence observée par strate), pente et intercept, indice de calibration intégré [33] ; l'exigence d'une calibration rapportée avec la même rigueur que la discrimination suit les meilleurs exemples du domaine [34] ;
- **score global** — score de Brier à H et sa version normalisée (IPA) [35].

La **valeur incrémentale** — le cœur du projet — est lue via les écarts entre modèles (Δ AUC, Δ Brier), les indices de reclassement NRI/IDI [36] rapportés *avec réserve* (sensibles au choix des seuils, non décisionnels seuls), et l'analyse de courbe de décision / bénéfice net [37]. Une métrique primaire est **pré-spécifiée** (AUC à 1 an ; IPA à 1 an) pour s'interdire de choisir après coup la métrique la plus flatteuse, et aucun écart entre modèles n'est commenté sans son intervalle de confiance à 95 %, obtenu par bootstrap au niveau patient.

4.6 Le dispositif de mesure : lire un écart sans se tromper soi-même

Les écarts en jeu — quelques centièmes d'AUC entre marches de l'échelle, quelques millièmes entre variantes proches — sont petits devant les sources de variabilité de la mesure. Trois règles en tirent les conséquences.

Tout écart se lit contre sa dispersion et contre un comparateur apparié. À découpage fixé, le seul changement de la graine aléatoire déplace l'AUC d'une expérience d'une amplitude comparable aux écarts que l'on cherche à mesurer ; une performance n'est donc jamais rapportée comme un point isolé, et un delta n'est calculé qu'entre deux bras partageant le même dispositif (mêmes patients, même découpage, même procédure de sélection) — faute de quoi le delta mesure le dispositif autant que le modèle. La robustesse des effets principaux est en outre vérifiée en répétant l'entraînement sous plusieurs graines.

La sélection est traitée comme une opération dangereuse. L'arrêt précoce d'un fine-tuning, comme le choix d'une configuration parmi des variantes proches, est une *sélection* opérée sur une métrique bruitée : la majorité de ces décisions se jouent à une amplitude inférieure à la dispersion de la métrique qui les fonde. Les classements fins entre variantes ne sont donc pas interprétés ; seuls les écarts entre *marches* de l'échelle, grands devant cette dispersion, portent une conclusion.

L'estimation finale est pré-enregistrée sur un jeu verrouillé. Le développement — entraînements, sélection, comparaisons — se déroule intégralement sur la partition de développement, elle-même scindée entre apprentissage et tranches de validation, les bras d'une même comparaison subissant une procédure de sélection symétrique. Le jeu de test verrouillé (20 % des patients, réservé dès l'assemblage de la cohorte, section 3) n'est ouvert qu'une fois, pour une **passé d'estimation finale pré-enregistrée** : un document gelé avant toute exécution fixe les bras évalués — une échelle à un facteur par barreau, du clinique seul à la fusion avec l'encodeur adapté —, les contrastes appariés pré-spécifiés et leur contraste primaire, les métriques primaires (AUC et IPA à 1 an), le plan d'analyse (bootstrap patient à 2 000 rééchantillonnages, deltas appariés patient à patient), et les interdits : aucune seconde passe, aucun ré-réglage, aucun bras ajouté ou retiré, aucune substitution de métrique, et les résultats de tous les bras rapportés quels qu'ils soient.

Ce document a été **gelé et signé le 27 août 2026**, avant toute ouverture du jeu de test. Il fixe

six bras qui échantillonnent l'échelle de représentations décrite plus haut — chaque bras combine un ou plusieurs de ses niveaux — et forment une échelle à un facteur par barreau : A1 clinique seul, A2 clinique + marqueurs conventionnels, A3 embeddings seuls, A4 clinique + embeddings gelés, A5 clinique + marqueurs + embeddings, A6 clinique + embeddings de l'encodeur adapté. Cinq contrastes appariés en découlent — chacun ne faisant varier qu'une chose entre deux bras voisins —, dont le **contraste primaire** $\mathbf{C3} = \mathbf{A4} - \mathbf{A1}$, l'apport de la fusion sur la référence clinique. Le modèle primaire désigné avant ouverture est **A4**, retenu par parcimonie : l'incrément des marqueurs par-dessus la fusion avait déjà été déclaré nul, et la ré-extraction corrigée a inversé l'ordre des estimations ponctuelles de A4 et A5 (0,8100 contre 0,8099) — démonstration que ce classement relève du bruit d'ajustement et non d'un fait sur les modèles. Le bras A6 estime la performance de **cet artefact d'adaptation précis**, non « l'apport du fine-tuning en général » : trois adaptations ne différant que par leur graine ont rendu des écarts aval couvrant une étendue de 0,0139, tous positifs, de sorte que le signe de ce contraste est établi mais son ampleur ne l'est pas.

4.7 Cadre de reporting

La démarche suit les recommandations TRIPOD+AI pour le reporting des modèles prédictifs cliniques [38], et l'auto-évaluation du risque de biais s'appuiera sur PROBAST+AI [39]. L'**explicabilité** des modèles (attributions cliniques, saillance sur l'ECG) est prévue comme perspective de la suite du projet plutôt que traitée ici (section 6).

5 Résultats

Les résultats rapportés ici proviennent de la **passé unique pré-enregistrée** sur le jeu de test verrouillé, ouverte le 27 août 2026 et exécutée une seule fois, sur l'état du code exactement gelé par le pré-enregistrement. La population évaluée compte **27 618 patients** et **838 événements de FA à un an** ; son identité a été vérifiée avant tout calcul (empreinte des identifiants confrontée à celle de la réserve de la cohorte). Aucun bras n'a été ajouté ni retiré, aucune métrique substituée, aucun réglage refait. Les chiffres de développement sont rappelés à titre de comparaison — ce sont ceux que la sélection a vus, et l'écart entre les deux colonnes fait partie du résultat.

5.1 Les six bras sur la réserve

TABLE 2 : Discrimination et score global des six bras pré-enregistrés, sur les 27 618 patients du jeu verrouillé.

Bras	AUC(365) jeu verrouillé [IC 95 %]	AUC dév.	IPA(365) [IC 95 %]	Pente de calibration
A1 clinique seul	0,7568 [0,7408 ; 0,7732]	0,7580	0,0411 [0,0348 ; 0,0472]	1,04
A2 clinique + marqueurs	0,7741 [0,7581 ; 0,7901]	0,7769	0,0550 [0,0465 ; 0,0636]	1,04
A3 embeddings seuls	0,8050 [0,7886 ; 0,8203]	0,7992	0,0896 [0,0755 ; 0,1033]	1,06

Bras	AUC(365) jeu verrouillé [IC 95 %]	AUC dév.	IPA(365) [IC 95 %]	Pente de calibration
A4 fusion clinique + embeddings — <i>primaire</i>	0,8144 [0,7989 ; 0,8292]	0,8100	0,0913 [0,0782 ; 0,1044]	1,04
A5 fusion + marqueurs	0,8148 [0,7991 ; 0,8294]	0,8099	0,0917 [0,0786 ; 0,1046]	1,05
A6 fusion, encodeur adapté	0,8187 [0,8031 ; 0,8330]	0,8331	0,0907 [0,0744 ; 0,1075]	0,99

Le tableau Table 2 appelle deux lectures, l’une sur les niveaux, l’autre sur les écarts au développement.

Pour les recettes figées tôt, la validation croisée s’est révélée un estimateur fidèle — sauf là où elle avait le plus servi à choisir. Cinq bras sur six rendent sur la réserve un chiffre à moins de 0,006 de leur estimation de développement, dans un sens ou dans l’autre. Le seul recul notable est celui du bras à encodeur adapté, **A6 : −0,0144** (0,8331 en développement, 0,8187 sur la réserve). C’est précisément le profil que la lecture pré-écrite du pré-enregistrement annonçait : A6 est le bras qui a subi la sélection la plus intense — choix d’encodeur, de graine, d’état d’entraînement — donc celui dont le chiffre de développement était le plus optimiste.

La calibration tient sur tous les bras : pentes comprises entre 0,99 et 1,06, intercepts nuls au millième, indice de calibration intégré inférieur ou égal à 0,008. Les risques prédits sont donc utilisables tels quels, sans recalibration — étant entendu qu’il s’agit du risque cause-spécifique défini en section 4, et non du risque absolu en présence de mortalité concurrente (section 7). C’est un point qui ne se lit pas dans la discrimination et que la seule AUC aurait masqué. La figure Figure 5 montre, pour le bras primaire face à la référence clinique, la calibration par décile de risque et le bénéfice net en fonction du seuil de décision — ce dernier restant supérieur pour la fusion sur toute la plage de seuils explorée.

À l’horizon secondaire de deux ans, l’ordre des bras et l’ampleur des écarts sont inchangés (A1 0,7620, A4 0,8129, A6 0,8181), les scores globaux montant mécaniquement avec l’horizon.

5.2 Les cinq contrastes pré-spécifiés

Chaque contraste est un delta apparié patient à patient — les six bras ayant été évalués sur exactement la même population, l’appariement est total — avec un intervalle de confiance bootstrap sur 2 000 rééchantillonnages au niveau patient. Le critère de lecture est celui qui avait été pré-spécifié : un apport est tenu pour **établi** lorsque l’intervalle de confiance à 95 % du delta exclut zéro, et pour **non établi** sinon.

Bras primaire (A4) face à la référence clinique (A1) — jeu de test verrouillé




FIGURE 5 : Bras primaire (A4) face à la référence clinique (A1) sur le jeu verrouillé, à 365 jours : calibration par décile (gauche) et courbe de décision (droite).

TABLE 3 : Les cinq contrastes pré-spécifiés, en deltas appariés sur le jeu verrouillé.

	Contraste	Question	$\Delta\text{AUC}(365)$ [IC 95 %]	$\Delta\text{c-index}$ d'Uno [IC 95 %]	Repère dév.
C1	A2 — A1	les marqueurs ajoutent-ils au clinique ?	+0,0174 [+0,0107 ; +0,0243]	+0,0162 [+0,0099 ; +0,0251]	+0,0189
C2	A3 — A1	l'ECG profond seul bat-il le clinique ?	+0,0482 [+0,0335 ; +0,0634]	+0,0496 [+0,0319 ; +0,0646]	+0,0412
C3	A4 — A1	<i>primaire</i> — que gagne la fusion ?	+0,0577 [+0,0466 ; +0,0692]	+0,0580 [+0,0453 ; +0,0700]	+0,0520
C4	A5 — A4	les marqueurs ajoutent-ils <i>par-dessus</i> les embeddings ?	+0,0003 [−0,0001 ; +0,0007]	+0,0003 [+0,0001 ; +0,0010]	−0,0001
C5	A6 — A4	l'adaptation de l'encodeur apporte-t-elle ?	+0,0042 [−0,0009 ; +0,0097]	+0,0038 [−0,0035 ; +0,0082]	+0,0231

Les cinq contrastes pré-spécifiés, sur le jeu de test verrouillé

27 618 patients · 838 événements · deltas appariés patient à patient · le rouge marque le contraste primaire



L'échelle tient barreau par barreau. Les marqueurs conventionnels de l'électrocardiographe ajoutent au dossier clinique (C1, +0,017), et la représentation apprise du signal dépasse à elle seule le dossier clinique complet (C2, +0,048). Aucune marche ne s'effondre : l'échelle se lit donc comme une progression cohérente, et non comme une collection de modèles hétérogènes.

La comparaison de C1 et C4 répond à Q2 de façon dissymétrique, et c'est le résultat le plus instructif du lot. Les marqueurs conventionnels apportent quelque chose au clinique seul (+0,017), mais **plus rien une fois les embeddings présents** (+0,0003, intervalle contenant zéro). En pratique prédictive, la représentation apprise couvre donc ce que portent les marqueurs, quand l'inverse n'est pas vrai. Une précision d'honnêteté : sur le c-index d'Uno, métrique secondaire et non décisionnelle, l'intervalle de C4 exclut zéro d'un dix-millième — à cette échelle, cela démontre la finesse que permet l'appariement, non qu'un dix-millième importe.

L'apport de l'adaptation de l'encodeur n'est pas établi. Le contraste C5 rend **+0,0042** $[-0,0009 ; +0,0097]$ à l'horizon primaire : l'intervalle contient zéro, alors que le développement annonçait +0,0231 avec un signe établi sur trois graines. Deux explications se combinent, toutes deux écrites avant l'ouverture. D'une part, A6 est le bras que la sélection a le plus favorisé, et son estimation de développement s'est comportée en conséquence. D'autre part, l'ampleur de l'adaptation dépendait fortement du tirage aléatoire — trois adaptations ne différant que par leur graine couvraient une étendue de 0,0139 —, et 838 événements ne suffisent pas à trancher un effet de cet ordre ; le pré-enregistrement avait explicitement écrit que la passe ne départagerait pas deux modèles proches. Ce que ce résultat ne dit pas : que l'adaptation soit sans valeur — l'estimation ponctuelle reste positive aux deux horizons, et l'intervalle à deux ans exclut zéro de justesse. Ce qu'il dit : **l'apport du fine-tuning ne peut pas être revendiqué comme un résultat établi**, et ne l'est pas ici.

Aucun modèle n'est redésigné. A4 demeure le modèle primaire, conformément à l'engagement pris avant l'ouverture. A5 et A6 le dépassent en estimation ponctuelle de +0,0004 et +0,0042 — des écarts que le pré-enregistrement avait d'avance rangés parmi le bruit de classement, et que rien dans ces résultats ne fait sortir de cette catégorie.

6 Discussion

Ce travail apporte deux résultats de nature différente. Le premier est un chiffre : sur des données verrouillées, la fusion du dossier clinique et d'une représentation apprise de l'ECG gagne près de six centièmes d'AUC sur un comparateur clinique entraîné dans les mêmes conditions. Le second est une leçon de méthode, obtenue le même jour et par le même dispositif : un apport que le développement donnait pour acquis — celui de l'adaptation de l'encodeur — ne s'est pas confirmé. Les deux comptent, et le second n'est pas le prix à payer du premier : c'est ce qui met le premier à l'abri du reproche le plus courant fait à ce genre de résultat.

6.1 Un apport de l'ECG, dans une littérature qui ne s'accorde pas

La question de l'apport propre de l'ECG au-delà du clinique divise. Certains travaux concluent que l'ECG profond dépasse un score clinique [7], d'autres le trouvent inférieur en validation externe [8], d'autres encore ne relèvent de gain que dans la **combinaison** des deux sources [9,10]. Nos résultats se rangent du côté d'un apport réel : dans notre cadre, la représentation apprise dépasse *seule* le dossier clinique complet, et la fusion ajoute encore à cela — un profil que ces travaux n'observaient pas tous.

Cette convergence mérite deux prudences. D'abord, les niveaux de performance ne se comparent

pas d’une cohorte à l’autre : la performance atteignable dépend fortement de l’horizon considéré — la discrimination rapportée dans le domaine décroît d’environ trois centièmes d’AUROC à chaque doublement d’horizon [6] — et de la population. Ce qui se compare, ce sont les *écarts* mesurés dans un même cadre, et c’est pourquoi tout ce document raisonne en contrastes appariés plutôt qu’en niveaux. Ensuite, notre validation reste interne : la leçon de [8] est précisément qu’un modèle supérieur dans sa cohorte d’origine peut s’inverser ailleurs.

Un résultat secondaire éclaire la nature de l’information captée. Les marqueurs conventionnels de l’électrocardiographie ajoutent au dossier clinique, mais plus rien une fois la représentation apprise présente. Cette dissymétrie suggère que la représentation apprise couvre, en pratique prédictive, l’essentiel de ce que portent les mesures classiques, et davantage — sans qu’on puisse conclure à une inclusion au sens strict, ni dire ici de quoi ce surplus est fait. C’est un argument en faveur de l’intérêt des représentations apprises, à tempérer aussitôt : un examen systématique de modèles de fondation ECG montre qu’ils ne dominent pas toujours une référence supervisée bien construite, y compris sur des tâches pronostiques [40]. C’est aussi la raison pour laquelle la question de l’explicabilité (ci-dessous) reste ouverte.

6.2 Ce que le dispositif a retiré

Le contraste sur l’adaptation de l’encodeur est le résultat le plus instructif de ce travail, précisément parce qu’il déçoit. En développement, l’adaptation paraissait apporter un gain substantiel, de signe établi sur trois graines. Sur la réserve verrouillée, l’intervalle contient zéro.

Rien dans ce renversement n’est mystérieux, et il n’a rien d’un accident : les deux mécanismes en cause étaient écrits *avant* l’ouverture. D’une part, le bras adapté est celui qui avait subi la sélection la plus intense — choix d’encodeur, de graine, d’état d’entraînement —, et c’est précisément le bras qui recule le plus entre développement et réserve, quand les cinq autres tiennent à moins de six millièmes. Le biais du vainqueur n’est pas ici une notion abstraite : sur ce bras, il a une amplitude observable, du même ordre que l’effet recherché. D’autre part, la recette d’adaptation présentait une variance de graine dont l’étendue dépassait l’effet à démontrer — un régime où l’adaptation d’une représentation pré-entraînée est connue pour être instable, et parfois coûteuse [23] ; aucune estimation sur 838 événements ne pouvait trancher un effet de cette taille, et le pré-enregistrement l’avait annoncé.

Il faut donc énoncer ce résultat avec exactitude, dans les deux sens. Il ne dit pas que le *fine-tuning* d’encodeurs ECG soit sans valeur : l’estimation ponctuelle reste positive aux deux horizons, et l’échec d’une recette particulière ne se généralise pas en échec d’une approche. Il dit que **l’apport de cette adaptation-là ne peut pas être revendiqué comme établi** — et ce document ne le revendique pas.

6.3 La mesure comme problème de recherche

Trois épisodes de ce projet racontent la même chose, et forment sa contribution méthodologique.

Le premier est un résultat nul qui n’en était pas un : l’apparente inutilité des comorbidités s’est révélée être un artefact de périmètre de codage, un ensemble de variables silencieusement vidées. Corrigé, le défaut a déplacé la question au lieu de la clore. La leçon vaut au-delà du cas : en apprentissage automatique appliqué à la santé, la qualité du pipeline de données pèse autant que le choix du modèle, et un résultat — surtout négatif — s’audite avant de s’interpréter.

Le deuxième est la découverte que les décisions de sélection du fine-tuning se prenaient, pour

l'essentiel, sous le niveau de bruit de la métrique qui les fondait. Un critère peut être parfaitement fidèle et néanmoins incapable de trancher ; c'est ce qui a conduit à ne pas interpréter les classements fins entre variantes proches, et à ne conclure que sur des écarts grands devant cette dispersion.

Le troisième est le renversement décrit plus haut : un apport tenu pour acquis en développement, que la réserve verrouillée n'a pas confirmé. Ensemble, ils justifient le dispositif de la section 4 — comparateurs appariés, lecture des écarts contre leur dispersion, passe unique pré-enregistrée — non comme une précaution de forme, mais comme la condition pour que les chiffres annoncés veuillent dire quelque chose. C'est ce qui permet de rapporter ces chiffres sans la réserve de sélection qui s'attache habituellement à une performance mesurée là où elle a été optimisée.

Cette insistance rejoint la question Q3. Une part du désaccord de la littérature pourrait tenir au cadre d'évaluation autant qu'au signal : plusieurs travaux traitent la survenue de FA comme une classification binaire à censure naïve [7,8], ce qui, dans une cohorte à censure lourde et probablement informative, déforme l'apport apparent d'un modèle — sans que le sens de la déformation soit connu d'avance. Notre cadre ne permet pas de quantifier cette part, faute d'avoir reproduit les protocoles concurrents sur nos données ; il permet en revanche d'affirmer que les écarts rapportés ici ne doivent rien à une censure mal traitée.

6.4 Portée clinique, et ce qui manque

La calibration observée est bonne : les risques annoncés sont utilisables tels quels, sans recalibration, ce qu'aucune mesure de discrimination n'aurait révélé. C'est une condition nécessaire à tout usage décisionnel, et elle est remplie sur cette population.

Elle n'est pas suffisante. Une bonne discrimination et une bonne calibration ne disent rien du bénéfice décisionnel réel, qui dépend des seuils d'action et de leurs conséquences [37], ni de l'insertion d'un tel modèle dans une pratique — un stade d'évaluation distinct, avec ses propres exigences [41]. Aucune utilité clinique n'est donc revendiquée ici.

Deux manques bornent la portée de ces résultats et ouvrent la suite. Le premier est l'absence de validation externe : tout a été mesuré dans un même système hospitalier, et la transportabilité reste entière à établir — c'est la limite que le dispositif ne pouvait pas lever, par construction. Le second est l'explicabilité : la dissymétrie entre marqueurs et embeddings montre que l'encodeur capte quelque chose de plus que les mesures conventionnelles, sans dire quoi. Répondre demanderait des méthodes d'attribution adaptées au cadre de survie à risques concurrents, où l'objet à expliquer n'est pas une classe mais un risque absolu à un horizon donné — un travail à part entière, et une perspective naturelle de ce projet.

7 Limites

Les limites qui suivent ne sont pas des réserves de forme : elles conditionnent l'interprétation de tout résultat et, pour plusieurs, la possibilité même de conclure. Elles sont donc énoncées précisément plutôt que génériquement.

Biais de surveillance et de détection. Sur une base hospitalière rétrospective, un patient plus sévère ou plus suivi a mécaniquement plus de chances qu'une FA soit *détectée et codée* — non parce que son risque biologique est plus élevé, mais parce qu'il est davantage monitoré. Ce mécanisme est documenté à ses deux étages : dans les dossiers de soins, les signaux de processus (le fait même qu'un examen soit prescrit, et quand) prédisent souvent le devenir des patients mieux que le résultat

de l'examen [42], et pour la FA spécifiquement, la prévalence détectée dépend du mode de recherche de l'arythmie — la détection clinique de routine en manque une part substantielle par rapport au monitoring systématique [43]. Un modèle peut alors apprendre en partie l'**intensité du suivi médical** plutôt que le risque intrinsèque de FA. C'est sans doute la limite la plus sérieuse d'un travail fondé sur MIMIC-IV, et elle borne l'interprétation causale comme la transportabilité des modèles. Elle n'est pas levée par le jeu de test verrouillé : celui-ci protège des biais de sélection *de notre part*, non des biais présents dans les données elles-mêmes, qu'il partage avec l'ensemble de développement.

Qualité et complétude du label. L'événement repose sur des codes diagnostiques, qui manquent les FA silencieuses ou non codées. Ces faux négatifs de label **bornent la performance atteignable** et faussent en particulier les métriques sensibles au déséquilibre. La correction du périmètre de codage ICD-9/ICD-10 des comorbidités a d'ailleurs montré qu'une définition incomplète pouvait produire des artefacts marqués (section 6).

Sensibilité aux choix de définition. La définition de l'événement retenue ici — codes I48.x complétés par les mentions du compte rendu, flutter inclus, période de blanking de quatorze jours — est un choix, et d'autres travaux en retiennent d'autres, ce qui borne la comparabilité directe des performances. Les trois points les plus discutables de ce choix ont fait l'objet d'analyses de sensibilité dédiées (censure précoce, inclusion du flutter, durée du blanking, section 3) : elles ne suppriment pas l'arbitraire de la définition, mais elles établissent que la cohorte ne dépend pas de façon critique de ces réglages.

Biais de sélection et généralisabilité. La cohorte est issue d'un centre unique et d'une population de soins aigus ; elle n'est pas représentative d'une population ambulatoire de dépistage. Les performances observées ne peuvent donc être extrapolées à d'autres contextes sans validation dédiée.

Censure informative résiduelle. La censure est lourde et probablement informative (section 3). La pondération IPCW réduit le biais correspondant, mais sous l'hypothèse d'une censure conditionnellement aléatoire sachant les covariables du modèle de censure ; si la censure dépend de facteurs non observés, un **bias résiduel subsiste**. L'IPCW atténue le problème, il ne le supprime pas.

Cadrage cause-spécifique du risque concurrent. L'analyse primaire traite le décès comme un non-événement (cible *cause-spécifique*), la modélisation en sous-distribution (risque *absolu* en présence de mortalité concurrente) étant reportée. Les probabilités prédites estiment donc un risque *conditionnel* — « si le décès n'intervient pas » — et non le risque absolu. Avec 8,5 % de décès concurrents (section 3), cette distinction importe pour toute communication clinique du risque, et nuance la bonne calibration observée : elle vaut pour la quantité effectivement estimée.

Puissance de l'estimation finale. Le jeu verrouillé compte 838 événements à l'horizon primaire, ce qui suffit à établir un écart de l'ordre de cinq centièmes d'AUC mais **pas à trancher un écart de quelques millièmes**. C'est une limite structurelle, que le pré-enregistrement avait anticipée : la passe est un instrument d'estimation, pas d'arbitrage fin. Elle explique pourquoi le contraste sur l'adaptation de l'encodeur reste indécidable (section 5), et pourquoi les écarts entre les trois bras de tête ne sont pas interprétés comme un classement. Une réserve plus grande aurait resserré les intervalles, au prix d'un ensemble de développement plus petit ; la fraction retenue — un cinquième des patients — est un compromis usuel, arbitré à la construction de la cohorte et non rejouable après coup.

Effets de sélection, mesurés plutôt que redoutés. Les estimations de développement de cinq

bras sur six se sont révélées fidèles à moins de six millièmes près, mais celle du bras le plus sélectionné était optimiste de plus d'un centième. Cela signifie que **toute performance rapportée dans ce projet hors de la passe finale — y compris celles des campagnes exploratoires — doit être lue comme potentiellement optimiste**, et d'autant plus qu'elle a été retenue parmi davantage de candidats. Le tableau de bord de développement du projet n'est pas un tableau de résultats, et il n'est pas cité comme tel dans ce document.

Dépendance des écarts au dispositif de comparaison. Un écart entre deux modèles n'est pas une propriété du modèle seul : il dépend du comparateur retenu et du protocole partagé. Les contrastes de la section 5 sont appariés patient à patient sur une population identique, ce qui neutralise cette dépendance à l'intérieur de la passe ; en revanche, aucune comparaison directe n'est légitime entre nos chiffres et ceux d'une autre étude, dont le dispositif diffère.

Variance de graine des recettes d'adaptation. L'ampleur de l'adaptation de l'encodeur dépend fortement du tirage aléatoire d'entraînement, dans une mesure comparable à l'effet recherché. Tout résultat portant sur le fine-tuning se rapporte donc à un artefact particulier, et non à la recette en général — ce qui limite ce qu'on peut en conclure, dans un sens comme dans l'autre.

Absence de validation externe. Les résultats sont internes à MIMIC-IV. Le jeu verrouillé protège du biais de sélection, mais partage tout le reste avec l'ensemble de développement : mêmes hôpitaux, même recrutement, mêmes pratiques de codage. Or la performance d'un modèle de prédiction de FA ne se transporte pas d'une population à l'autre : un modèle performant en interne peut se révéler inférieur à un score clinique en validation externe [8], et la discrimination des scores cliniques eux-mêmes varie fortement selon les cohortes [12]. Aucune prétention d'utilité clinique ne peut donc être formulée sans validation indépendante. C'est le manque le plus important de ce travail, et le dispositif de mesure ne pouvait pas le combler — il n'était pas conçu pour cela.

Fuite potentielle via l'encodeur pré-entraîné. Plusieurs encodeurs ECG candidats sont pré-entraînés sur MIMIC-IV [17,18,44] : si des patients de l'ensemble d'évaluation ont participé à ce pré-entraînement, une fuite est possible. Ce risque est écarté pour les bras de la passe finale, dont l'encodeur est pré-entraîné hors de MIMIC [19] et dont l'adaptation n'a jamais vu un signal du jeu verrouillé. Il demeure pour les comparaisons d'encodeurs menées en développement, où le non-chevauchement n'est pas établi pour tous les candidats.

Performance statistique et utilité clinique. Une bonne discrimination et une bonne calibration ne garantissent pas un bénéfice décisionnel : celui-ci dépend des seuils d'action et de leurs conséquences, et sa démonstration relèverait d'une évaluation clinique dédiée, hors du périmètre de ce travail.

Interprétabilité. Les représentations apprises restent difficiles à interpréter, alors même que les résultats montrent qu'elles captent davantage que les marqueurs conventionnels. Ce qu'elles captent n'est pas caractérisé ici, et l'explicabilité est renvoyée aux perspectives (section 6).

8 Conclusion

Ce travail cherchait à savoir si une représentation d'un ECG 12-dérivations apporte une information prédictive de la fibrillation atriale *incidente* au-delà d'un modèle clinique de référence, et laquelle des représentations disponibles y contribue le plus. En comparant des niveaux d'information croissants — clinique, marqueurs conventionnels, représentation apprise gelée, représentation adaptée, et leurs fusions — plutôt qu'en opposant deux modèles, il visait à isoler l'apport propre de chaque source.

La réponse à la première question est positive, et établie sur des données qu'aucune étape de sélection

n'avait touchées : la fusion du dossier clinique et d'une représentation apprise de l'ECG gagne près de six centièmes d'AUC sur le comparateur clinique, avec des risques prédits — au sens cause-spécifique défini en méthodes — directement calibrés. La réponse à la seconde est dissymétrique : la représentation apprise couvre, en pratique prédictive, l'information des marqueurs conventionnels, quand l'inverse n'est pas vrai ; l'apport de l'adaptation de l'encodeur, lui, n'est pas établi sur données verrouillées, quand le développement le donnait pour acquis.

Ce dernier point n'est pas un échec du dispositif : c'en est le produit. Une passe d'estimation unique, pré-enregistrée avant toute ouverture du jeu de test, a confirmé un résultat et en a retiré un autre — et la même journée a montré, chiffres à l'appui, que le bras ayant subi le plus de choix était celui dont l'estimation de développement était la plus optimiste. C'est ce qui autorise à présenter le premier résultat sans la réserve habituelle sur la sélection, et c'est la contribution que ce travail revendique au même titre que sa mesure.

Deux manques bornent la portée de l'ensemble. La validation reste **interne** : mêmes hôpitaux, mêmes pratiques de codage, et le verrou du jeu de test ne protège en rien de ce que la population partage avec elle-même. Et ce que la représentation apprise capte de plus que les mesures conventionnelles n'est pas caractérisé. Aucune utilité clinique n'est donc revendiquée ici : elle supposerait une validation indépendante, puis une évaluation du bénéfice décisionnel réel — c'est-à-dire un autre travail que celui-ci, dont ce document établit la base mesurée.

9 Usage de l'intelligence artificielle dans ce travail

Ce travail a été réalisé avec l'assistance d'un agent IA de codage (Claude Code, Anthropic), utilisé comme outil d'exécution sous supervision humaine constante, et non comme auteur des choix méthodologiques ou des interprétations.

Trois usages peuvent être distingués.

Implémentation. Le code (cohorte, features, modèles, évaluation) a été développé avec l'agent en suivant le workflow *spec-kit*, un outil tiers de structuration du développement assisté par IA : chaque brique est précédée d'une spécification et d'un plan explicites (répertoire *specs/*) avant toute implémentation, ce qui borne le périmètre de l'agent et laisse une trace des décisions.

Rédaction et gestion de la base de connaissance. Le journal de bord, les notes de concept, les rapports de cohorte et d'expérience sont consignés dans un vault Obsidian (*docs/*). Leur mise à jour s'appuie sur un ensemble de skills conçus par l'auteur pour ce projet (*journal*, *ingest-cohort*, *ingest-experiment*, *ingest-lecture*) : l'agent y rédige des **brouillons** factuels, ancrés aux artefacts produits par le code (fichiers *summary.json*, *results.parquet*), jamais des chiffres inventés ; l'interprétation méthodologique et la validation de chaque note restent de la responsabilité de l'auteur.

Rédaction du manuscrit. La rédaction de ce document s'appuie sur un second ensemble de skills conçus par l'auteur (*ArtKit*) : constitution du plan argumentatif, matrice de preuves reliant chaque affirmation à sa source (note du vault ou référence bibliographique), rédaction section par section à partir de ces sources autorisées, puis relecture critique. Toute affirmation non sourcée est signalée par un TODO plutôt que comblée par une invention. La préparation de la soutenance orale suit le même principe (*OralKit*).

La passe d'estimation finale sur le jeu de test verrouillé, elle, a été gelée par pré-enregistrement signé puis lancée manuellement par l'auteur — l'agent n'a ni le droit ni le moyen de l'ouvrir. Dans les

trois cas, l'agent produit du texte ou du code à valider ; les choix de méthode, les interprétations des résultats et la décision finale de retenir ou non une proposition restent intégralement de la responsabilité de l'auteur.

10 Références

1. Linz D, Gawalko M, Betz K, Hendriks JM, Lip GYH, Vinter N, et al. Atrial Fibrillation : Epidemiology, Screening and Digital Health. The Lancet Regional Health – Europe. 2024. doi :[10.1016/j.lanepe.2023.100786](https://doi.org/10.1016/j.lanepe.2023.100786)
2. Kalantarian S, Ay H, Gollub RL, Lee H, Retzepe K, Mansour M, et al. Association Between Atrial Fibrillation and Silent Cerebral Infarctions : A Systematic Review and Meta-Analysis. Annals of Internal Medicine. 2014. doi :[10.7326/M14-0538](https://doi.org/10.7326/M14-0538)
3. Testai FD, Gorelick PB, Chuang PY, et al. Cardiac Contributions to Brain Health : A Scientific Statement From the American Heart Association. Stroke. 2024. doi :[10.1161/STR.0000000000000476](https://doi.org/10.1161/STR.0000000000000476)
4. Attia ZI, Noseworthy PA, Lopez-Jimenez F, Asirvatham SJ, Deshmukh AJ, Gersh BJ, et al. An Artificial Intelligence-Enabled ECG Algorithm for the Identification of Patients With Atrial Fibrillation During Sinus Rhythm. The Lancet. 2019. doi :[10.1016/S0140-6736\(19\)31721-0](https://doi.org/10.1016/S0140-6736(19)31721-0)
5. Raghunath S, Pfeifer JM, Fornwalt BK, Haggerty C, et al. Deep Neural Networks Can Predict New-Onset Atrial Fibrillation From the 12-Lead ECG and Help Identify Patients at Risk for Stroke. Circulation. 2021. doi :[10.1161/CIRCULATIONAHA.120.047829](https://doi.org/10.1161/CIRCULATIONAHA.120.047829)
6. Saiz-Vivo J, Chakravarthy N, Ho WHH, Ching CK, Yeung WLK, Lim TW, et al. Artificial Intelligence for Atrial Fibrillation Prediction in Sinus Rhythm : A Narrative Review. European Heart Journal – Digital Health. 2026. doi :[10.1093/ehjdh/ztaf144](https://doi.org/10.1093/ehjdh/ztaf144)
7. Jabbour G, Nolin-Lapalme A, Tastet O, Corbin D, Jordà P, Sowa A, et al. Prediction of Incident Atrial Fibrillation Using Deep Learning, Clinical Models, and Polygenic Scores. European Heart Journal. 2024;45:4920-34. doi :[10.1093/eurheartj/ehae595](https://doi.org/10.1093/eurheartj/ehae595)
8. Brant LCC, Ribeiro AH, Eromosele OB, Pinto-Filho MM, Barreto SM, Duncan BB, et al. Prediction of Atrial Fibrillation From the ECG in the Community Using Deep Learning : A Multinational Study. Circulation : Arrhythmia and Electrophysiology. 2025. doi :[10.1161/CIRCEP.125.013734](https://doi.org/10.1161/CIRCEP.125.013734)
9. Christopoulos G, Graff-Radford J, Lopez CL, Yao X, Attia ZI, Rabinstein AA, et al. Artificial Intelligence–Electrocardiography to Predict Incident Atrial Fibrillation : A Population-Based Study. Circulation : Arrhythmia and Electrophysiology. 2020. doi :[10.1161/CIRCEP.120.009355](https://doi.org/10.1161/CIRCEP.120.009355)

10. Zheng Y, Siontis KC, Attia ZI, Shiri I, Roten L, Baj G, et al. Artificial Intelligence 12-Lead Electrocardiography to Determine Atrial Fibrillation Risk Among UK Biobank Participants With Predisposing Conditions. *European Heart Journal – Digital Health*. 2026. doi :[10.1093/eh-jdh/ztag025](https://doi.org/10.1093/eh-jdh/ztag025)
11. Alonso A, Krijthe BP, Aspelund T, Stepas KA, Pencina MJ, Benjamin EJ. Simple Risk Model Predicts Incidence of Atrial Fibrillation in a Racially and Geographically Diverse Population : the CHARGE-AF Consortium. *Journal of the American Heart Association*. 2013. doi :[10.1161/JAHA.112.000102](https://doi.org/10.1161/JAHA.112.000102)
12. Alonso A, Norby FL. Predicting Atrial Fibrillation and Its Complications. *Circulation Journal*. 2016. doi :[10.1253/circj.CJ-16-0239](https://doi.org/10.1253/circj.CJ-16-0239)
13. Kamada H, Kawasoe S, Kubozono T, Ninomiya Y, Enokizono K, Yoshimoto I, et al. Simple Risk Scoring Using Sinus Rhythm Electrocardiograms Predicts the Incidence of Atrial Fibrillation in the General Population. *Scientific Reports*. 2024. doi :[10.1038/s41598-024-60219-y](https://doi.org/10.1038/s41598-024-60219-y)
14. Hu EJ, Shen Y, Wallis P, Allen-Zhu Z, Li Y, Wang S, et al. LoRA : Low-Rank Adaptation of Large Language Models. *arXiv*. 2021. doi :[10.48550/arXiv.2106.09685](https://doi.org/10.48550/arXiv.2106.09685)
15. Johnson AEW, Bulgarelli L, Shen L, et al. MIMIC-IV, a Freely Accessible Electronic Health Record Dataset. *Scientific Data*. 2023 ;10. doi :[10.1038/s41597-022-01899-x](https://doi.org/10.1038/s41597-022-01899-x)
16. Gow B, Pollard T, Nathanson LA, et al. MIMIC-IV-ECG : Diagnostic Electrocardiogram Matched Subset. *PhysioNet* ; 2023. doi :[10.13026/4nqg-sb35](https://doi.org/10.13026/4nqg-sb35)
17. McKeen K, Masood S, Toma A, Rubin B, Wang B. ECG-FM : An Open Electrocardiogram Foundation Model. *arXiv*. 2025.
18. Moody JB, Poitrasson-Rivière A, Renaud JM, Hagio T, Al-Mallah MH, Goonewardena SN, et al. A Foundation Transformer Model With Self-Supervised Learning for ECG-Based Assessment of Cardiac and Coronary Function. *NEJM AI*. 2025 ;2(12). doi :[10.1056/aioa2500164](https://doi.org/10.1056/aioa2500164)
19. Na Y, Park M, Tae Y, Joo S. Guiding Masked Representation Learning to Capture Spatio-Temporal Relationship of Electrocardiogram. In : *International Conference on Learning Representations (ICLR)*. 2024.
20. Kim S. Learning General Representation of 12-Lead Electrocardiogram with a Joint-Embedding Predictive Architecture. *arXiv*. 2024.
21. Li J, Aguirre A, Moura J, Liu C, Zhong L, Sun C, et al. An Electrocardiogram Foundation Model Built on Over 10 Million Recordings With External Evaluation Across Multiple Domains (ECGFounder). *arXiv*. 2025.
22. Filice F, De Rose E, Bartucci S, Calimeri F, Perri S. Looking Beyond Accuracy : A Holistic Benchmark of ECG Foundation Models. *arXiv*. 2026.

23. Kumar A, Raghunathan A, Jones R, Ma T, Liang P. Fine-Tuning can Distort Pretrained Features and Underperform Out-of-Distribution. In : International Conference on Learning Representations (ICLR). 2022. doi :[10.48550/arXiv.2202.10054](https://doi.org/10.48550/arXiv.2202.10054)
24. Lee C, Zame WR, Yoon J, Schaar M van der. DeepHit : A Deep Learning Approach to Survival Analysis with Competing Risks. In : Proceedings of the AAAI Conference on Artificial Intelligence. 2018.
25. Kvamme H, Borgan Ø, Scheel I. Time-to-Event Prediction with Neural Networks and Cox Regression. Journal of Machine Learning Research. 2019 ;20.
26. Gopal B, Han R, Raghupathi G, Ng A, Tison G, Rajpurkar P. 3KG : Contrastive Learning of 12-Lead Electrocardiograms using Physiologically-Inspired Augmentations. In : Machine Learning for Health (ML4H), PMLR 158. 2021.
27. Lim J, Lee Y, Jang W, Joo S. Specialized ECG Data Augmentation Method : Leveraging Precordial Lead Positional Variability. Biomedical Engineering Letters. 2025 ;15:377-88. doi :[10.1007/s13534-024-00455-3](https://doi.org/10.1007/s13534-024-00455-3)
28. Rahman MM, Rivolta MW, Badilini F, Sassi R. A Systematic Survey of Data Augmentation of ECG Signals for AI Applications. Sensors. 2023 ;23(11):5237. doi :[10.3390/s23115237](https://doi.org/10.3390/s23115237)
29. Nonaka N, Seita J. Data Augmentation for Electrocardiogram Classification with Deep Neural Network. arXiv. 2020.
30. Raghu A, Shanmugam D, Pomerantsev E, Gutttag J, Stultz CM. Data Augmentation for Electrocardiograms. In : Proceedings of the Conference on Health, Inference, and Learning (CHIL), PMLR 174. 2022.
31. Robins JM, Rotnitzky A. Recovery of Information and Adjustment for Dependent Censoring Using Surrogate Markers. AIDS Epidemiology – Methodological Issues. 1992.
32. Uno H, Cai T, Tian L, Wei LJ. Evaluating Prediction Rules for t-Year Survivors With Censored Regression Models. Statistics in Medicine. 2007.
33. Austin PC, Steyerberg EW. The Integrated Calibration Index (ICI) and Related Metrics for Quantifying the Calibration of Logistic Regression Models. Statistics in Medicine. 2019.
34. Khurshid S, Friedman S, Lubitz SA, et al. Electrocardiogram-Based Deep Learning and Clinical Risk Factors to Predict Atrial Fibrillation. Circulation. 2022. doi :[10.1161/CIRCULATIONAHA.121.057480](https://doi.org/10.1161/CIRCULATIONAHA.121.057480)
35. Graf E, Schmoor C, Sauerbrei W, Schumacher M. Assessment and Comparison of Prognostic Classification Schemes for Survival Data. Statistics in Medicine. 1999.

36. Pencina MJ, D'Agostino RB, Vasan RS. Evaluating the Added Predictive Ability of a New Marker : From Area Under the ROC Curve to Reclassification and Beyond. *Statistics in Medicine*. 2008.
37. Vickers AJ, Elkin EB. Decision Curve Analysis : A Novel Method for Evaluating Prediction Models. *Medical Decision Making*. 2006. doi :[10.1177/0272989X06295361](https://doi.org/10.1177/0272989X06295361)
38. Collins GS, Moons KGM, Dhiman P, Riley RD, Van Calster B, Reitsma JB. TRIPOD+AI Statement : Updated Guidance for Reporting Clinical Prediction Models That Use Regression or Machine Learning Methods. *The BMJ*. 2024. doi :[10.1136/bmj-2023-078378](https://doi.org/10.1136/bmj-2023-078378)
39. Moons KGM, Damen JAA, Kaul T, Collins GS, Smeden M van. PROBAST+AI : An Updated Quality, Risk of Bias, and Applicability Assessment Tool for Prediction Models Using Regression or Artificial Intelligence Methods. *The BMJ*. 2025. doi :[10.1136/bmj-2024-082505](https://doi.org/10.1136/bmj-2024-082505)
40. Al-Masud MA, Lopez Alcaraz JM, Strodthoff N. Benchmarking ECG Foundation Models : A Reality Check Across Clinical Tasks. *arXiv*. 2025.
41. Vasey B, Nagendran M, Campbell B, Collins GS, McCulloch P. Reporting Guideline for the Early-Stage Clinical Evaluation of Decision Support Systems Driven by Artificial Intelligence : DECIDE-AI. *Nature Medicine*. 2022. doi :[10.1038/s41591-022-01772-9](https://doi.org/10.1038/s41591-022-01772-9)
42. Agniel D, Kohane IS, Weber GM. Biases in Electronic Health Record Data Due to Processes Within the Healthcare System : Retrospective Observational Study. *BMJ*. 2018;361:k1479. doi :[10.1136/bmj.k1479](https://doi.org/10.1136/bmj.k1479)
43. Hulstaert L, Boehme A, Hood K, Hayden J, Jackson C, Toyip A, et al. Assessing Ascertainment Bias in Atrial Fibrillation Across US Minority Groups. *PLOS ONE*. 2024;19(4):e0301991. doi :[10.1371/journal.pone.0301991](https://doi.org/10.1371/journal.pone.0301991)
44. Cai M, Jiang J, Huang W, Liu C, Arcucci R. SuPreME : A Supervised Pre-training Framework for Multimodal ECG Representation Learning. *arXiv*. 2025.